

FICHA DE PROCEDENCIA DE DATOS

Origen y licencia

Los tres ficheros con los que trabaja OncoLens

Este documento es una plantilla provisional. Se ha generado para dejar operativos los enlaces de descarga de la web mientras se termina la version definitiva. No contiene todavia el contenido final del proyecto.

oncoseq_expresion.parquet

Matriz de expresion genica, 1.680 muestras por 20.531 genes, medida por RNA-Seq en plataforma Illumina HiSeq. Procede de la coleccion PANCAN del proyecto TCGA. Fuente: portal.gdc.cancer.gov y synapse.org (syn4301332).

oncoseq_metadatos.csv

Etiqueta de cada muestra: barcode TCGA, participante, tipo de tejido y cohorte. 1.680 filas, sin valores nulos. La convencion de nombres es compatible con el dataset UCI 401 (Fiorini, 2016), publicado bajo CC BY 4.0. Nota: aquella version tiene 801 muestras, todas tumorales.

gene_names.csv

Traduccion de los identificadores anonimos a simbolo genico, cromosoma y longitud. 20.531 filas, de las cuales 20.502 tienen simbolo oficial HGNC. Derivado de `geneInfo.rda` del paquete TCGAbiolinks (Bioconductor).

Sobre los ficheros

Los tres fueron renombrados y reempaquetados por el equipo, de modo que los enlaces anteriores no descargan un archivo con esos nombres literales sino la fuente publica de la que proceden. Los datos de TCGA pertenecen a la categoria de acceso abierto y estan sujetos a la NIH Genomic Data Sharing Policy.

Pendiente de confirmar: el punto exacto de descarga de la matriz de expresion, no registrado en los cuadernos del proyecto.